

Atividade: Auditoria de Dados Clínicos e Justiça Algorítmica

1. Escopo do Projeto

O discente atuará no papel de um Engenheiro de Dados encarregado de auditar a base histórica "Breast Cancer Wisconsin (Diagnostic)" da UCI. O objetivo do projeto não é treinar um modelo preditivo, mas sim diagnosticar a saúde estatística dos dados, identificar anomalias clínicas e emitir um parecer sobre a viabilidade e os riscos éticos de utilizar este conjunto para sistemas de triagem na rede pública de saúde

2. Requisitos Analíticos e Entregáveis

O projeto deve ser estruturado em seções lógicas, garantindo a entrega dos seguintes artefatos e respostas computacionais:

Requisito I: Estruturação da Base de Dados

- **O que deve ser feito:** Ingestão da base de dados bruta, isolando exclusivamente as características morfológicas do núcleo celular (raio, perímetro, área, etc.) e o diagnóstico final do paciente.
- **Espera-se:** A variável alvo (diagnóstico) deve estar codificada em um formato matemático compatível com algoritmos de classificação binária. O ambiente deve exibir a volumetria final dos dados tratados.

Requisito II: Diagnóstico de Assimetria Biológica

- **O que deve ser feito:** Investigação da morfologia estatística da variável referente à área do núcleo celular.
- **Espera-se:** O sistema deve calcular e exibir métricas que comprovem matematicamente o distanciamento entre a tendência central e a dispersão extrema dos dados. É obrigatória a renderização de uma prova visual (gráfico de densidade) que evidencie o comportamento das caudas desta variável.

Requisito III: Isolamento Robusto de Anomalias

- **O que deve ser feito:** Identificação de pacientes que apresentam quadros clínicos estatisticamente anormais (outliers) no que tange à área celular. *Nota arquitetural: Devido à assimetria biológica comprovada no Requisito II, o discente deve escolher uma abordagem estritamente não-paramétrica para a definição do limite de corte.*
- **Espera-se:** O script deve isolar este subgrupo de pacientes atípicos e retornar duas saídas: o limite numérico de corte utilizado e a taxa de prevalência de tumores malignos encontrada *exclusivamente* dentro deste subgrupo isolado.

Requisito IV: Mapeamento de Multicolinearidade

- **O que deve ser feito:** Avaliação de redundância informacional entre os atributos extraídos das imagens celulares (ex: avaliar se o perímetro e a área informam a mesma coisa ao modelo).
- **Espera-se:** Geração de um artefato visual bidimensional que quantifique e exponha a correlação cruzada entre todas as variáveis geométricas.